

Предельные теоремы. Свойства оценок. Оценивание характеристик распределения.

Леонид Иосипой

Курс «Вероятностные модели и статистика»
Центр непрерывного образования, ВШЭ

15 апреля 2021

- Повторение
- Закон больших чисел
- Центральная предельная теорема. Концентрация II
- Свойства оценок
- Оценивание характеристик распределения

Повторение

1. Функции распределения.

Функцией распределения случайной величины X называется функция $F_X : \mathbb{R} \rightarrow [0, 1]$ задаваемая следующей формулой

$$F_X(u) = \mathbb{P}(X \leq u).$$

Повторение

1. Функции распределения.

Важное свойство функции распределения:


Любую случайную величину X можно задать через функцию распределения. То есть по функции распределения можно восстановить распределение случайной величины X :

- в дискретном случае можно восстановить a_k и p_k ;
- в непрерывном случае можно восстановить $f(u)$.

Повторение

1. Функции распределения.

График $F_X(u)$ для $X \sim \mathbf{B}_p$, $p \in [0, 1]$.




$$F_X(u) = \mathbb{P}(X \leq u).$$

Повторение

1. Функции распределения.

График $F_X(u)$ для $X \sim \text{Exp}(\lambda)$, $\lambda > 0$.



$$F_X(u) = \mathbb{P}(X \leq u).$$

$$F'_X(u) = f(u)$$

Повторение

1. Функции распределения.

Как найти плотность $Y = g(X)$, зная плотность X ?

- 1) Выразить функцию распределения $F_Y(u)$ через функцию распределения $F_X(u)$;
- 2) Продифференцировать $F_Y(u)$.

Повторение

2. Неравенства концентрации.

Теорема (Неравенство Маркова)

Пусть X — произвольная случайная величина. Тогда для любого $t > 0$

$$\mathbb{P}(|X| > t) \leq \frac{\mathbb{E}|X|}{t}.$$


Повторение

2. Неравенства концентрации.

Теорема (Неравенство Чебышёва)

Пусть X — произвольная случайная величина и $|\mathbb{E}X| < \infty$.
Тогда для любого $t > 0$

$$\mathbb{P}(|X - \mathbb{E}X| > t) \leq \frac{\text{Var } X}{t^2}.$$



Повторение

3. Распределение суммы случайных величин.

Пусть даны две независимые случайные величины X и Y :

- ▶ Дискретная свертка: если X и Y дискретные и принимают значения из \mathbb{Z} , то для произвольного $k \in \mathbb{Z}$

$$\mathbb{P}(X + Y = k) = \sum_{j=-\infty}^{+\infty} \mathbb{P}(X = j) \cdot \mathbb{P}(Y = k - j).$$

- ▶ Непрерывная свертка: если X и Y непрерывные и имеют плотности $f_X(u)$ и $f_Y(u)$ соответственно, то для $u \in \mathbb{R}$

$$f_{X+Y}(u) = \int_{-\infty}^{+\infty} f_X(z) f_Y(u - z) dz.$$

Повторение

4. Базовые операции.

- 1) Центрирование: вычитание из X ее мат. ожидания $\mathbb{E}X$,

$$\mathbb{E}[X - \mathbb{E}X] = \mathbb{E}[X] - \mathbb{E}[X] = 0;$$

- 2) Нормирование: деление X на $\sqrt{\text{Var}(X)}$,

$$\text{Var} \left(\frac{X}{\sqrt{\text{Var}(X)}} \right) = \left(\frac{1}{\sqrt{\text{Var}(X)}} \right)^2 \cdot \text{Var}(X) = 1;$$

- 3) Стандартизация: центрирование + нормирование,

$$\frac{X - \mathbb{E}X}{\sqrt{\text{Var}(X)}}.$$

Закон больших чисел

Пусть X_1, X_2, X_3, \dots — независимые одинаково распределенные случайные величины.


Определим $S_n = X_1 + \dots + X_n$.

Пусть $\mu = \mathbb{E}[X_1]$ и $\sigma^2 = \text{Var}(X_1) < \infty$.

Теорема (Закон больших чисел, ЗБЧ)

В обозначениях выше, для любого $t > 0$,

$$\mathbb{P}\left(\left|\frac{S_n}{n} - \mu\right| > t\right) \rightarrow 0 \quad \text{при } n \rightarrow \infty.$$



Закон больших чисел

Иногда закон больших чисел записывают так:

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu.$$

Знак « $\xrightarrow{\mathbb{P}}$ » обозначает **сходимость «по вероятности»**.

То есть правильно читать эту формулу так:

«Случайная величина S_n/n сходится к μ по вероятности».

Закон больших чисел

Доказательство. Найдем мат. ожидание и дисперсию S_n/n :

$$\mathbb{E} \left[\frac{S_n}{n} \right] = \frac{1}{n} \cdot \mathbb{E}[S_n] = \frac{1}{n} \cdot \left(\mathbb{E}[X_1] + \dots + \mathbb{E}[X_n] \right) = \frac{1}{n} \cdot n\mu = \mu,$$

$$\begin{aligned} \text{Var} \left(\frac{S_n}{n} \right) &= \frac{1}{n^2} \text{Var} (S_n) = \frac{1}{n^2} \left(\text{Var} X_1 + \dots + \text{Var} X_n \right) = \frac{1}{n^2} \cdot n\sigma^2 \\ &= \frac{\sigma^2}{n}. \end{aligned}$$

Воспользуемся неравенством Чебышёва:

$$\mathbb{P} \left(\left| \frac{S_n}{n} - \mu \right| > \varepsilon \right) \leq \frac{\text{Var} \left(\frac{S_n}{n} \right)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0 \quad \text{при } n \rightarrow \infty.$$

Центральная предельная теорема. Концентрация II

Итак, $\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu$, но как ведут себя отклонения? Нормально!

Теорема (Центральная предельная теорема, ЦПТ)

В обозначениях выше (которые для ЗБЧ), для любых $a < b$,

$$\mathbb{P} \left(a < \frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}} < b \right) \rightarrow \mathbb{P}(a < Z < b) \quad \text{при } n \rightarrow \infty,$$

где $Z \sim \mathcal{N}(0, 1)$. Если $\Phi(u)$ — функция распределения Z ,

$$\mathbb{P}(a < Z < b) = \Phi(b) - \Phi(a).$$

Центральная предельная теорема. Концентрация II

Обратите внимание, что:

- ▶ Стандартизация S_n/n и S_n дает один и тот же результат:

$$\frac{S_n/n - \mathbb{E}[S_n/n]}{\sqrt{\text{Var}(S_n/n)}} = \frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}}.$$

- ▶ Нормировка разности $S_n/n - \mathbb{E}[S_n/n]$ на $\sqrt{\text{Var}(S_n/n)}$ увеличивает ее значение в \sqrt{n} раз:

$$\frac{1}{\sqrt{\text{Var}(S_n/n)}} = \frac{\sqrt{n}}{\sigma}.$$

Центральная предельная теорема. Концентрация II

- Функция распределения $\Phi(u)$ стандартного нормального закона явно не вычисляется! Найти ее значение можно либо с помощью какого-либо программного обеспечения, либо по таблице.

Если Вы пользуетесь таблицей, то может быть полезна формула, которая следует из симметрии распределения:

$$\Phi(-u) = 1 - \Phi(u) \quad \text{для } u > 0.$$

Центральная предельная теорема. Концентрация II

Задача

Правильная монета подбрасывается 10 000 раз. Оцените с помощью неравенства Чебышёва и центральной предельной теоремы вероятность того, что число гербов отличается от 5000 не более, чем на 100.

Центральная предельная теорема. Концентрация II

Решение.

Пусть $X_1, \dots, X_n \sim \mathbf{B}_{1/2}$, $n = 10\,000$.

Как обычно: $S_n = X_1 + \dots + X_n$.

Найдем сначала мат. ожидание и дисперсию S_n :

$$\mathbb{E}[S_n] = \mathbb{E}[X_1 + \dots + X_n] = n \cdot \mathbb{E}[X_1] = np = 5\,000,$$

$$\text{Var}(S_n) = \text{Var}(X_1 + \dots + X_n) = n \cdot \text{Var}(X_1) = np(1 - p) = 2500.$$

Центральная предельная теорема. Концентрация II

По неравенству Чебышёва:

$$\begin{aligned}\mathbb{P}(|S_n - 5000| \leq 100) &= \mathbb{P}(|S_n - \mathbb{E}[S_n]| \leq 100) \\ &= 1 - \mathbb{P}(|S_n - \mathbb{E}[S_n]| > 100) \\ &\geq 1 - \frac{\text{Var}(S_n)}{100^2} \\ &= 1 - \frac{2500}{100^2} \\ &= 0.75.\end{aligned}$$

Что это значит?

Центральная предельная теорема. Концентрация II

По центральной предельной теореме:

$$\begin{aligned}\mathbb{P}(|S_n - 5000| \leq 100) &= \mathbb{P}(4900 \leq S_n \leq 5100) \\&= \mathbb{P}\left(\frac{4900 - 5000}{\sqrt{2500}} \leq \frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}} \leq \frac{5100 - 5000}{\sqrt{2500}}\right) \\&= \mathbb{P}\left(-2 \leq \frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}} \leq 2\right) \\&\approx \Phi(2) - \Phi(-2) \\&\approx 0.9544.\end{aligned}$$

Что это значит? Правильный ответ: 0.9545.

Центральная предельная теорема. Концентрация II

Задача

Мой дед любит ходить. Его шаги — независимые одинаково распределенные случайные величины, равномерно распределенные на $[70, 80]$ см. С какой вероятностью он за 10 000 шагов пройдет расстояние, отличное от 7.5 км. не более, чем на 10 м.?

Центральная предельная теорема. Концентрация II

Решение. Заметим, что в условии задачи числа даны в разных единицах измерения. Приведем все к метрам.

Пусть X_1, \dots, X_n имеют равномерное распределение на $[0.7, 0.8]$ м., $n = 10\,000$.

Как обычно: $S_n = X_1 + \dots + X_n$.

Найдем сначала мат. ожидание и дисперсию S_n :

$$\mathbb{E}[S_n] = \mathbb{E}[X_1 + \dots + X_n] = n \cdot \mathbb{E}[X_1] = n \cdot \frac{0.8 + 0.7}{2} = 7\,500,$$

$$\begin{aligned}\text{Var}(S_n) &= \text{Var}(X_1 + \dots + X_n) = n \cdot \text{Var}(X_1) = n \cdot \frac{(0.8 - 0.7)^2}{12} \\ &= \frac{100}{12}.\end{aligned}$$

Центральная предельная теорема. Концентрация II

По неравенству Чебышёва:

$$\begin{aligned}\mathbb{P}(|S_n - 7500| \leq 10) &= \mathbb{P}(|S_n - \mathbb{E}[S_n]| \leq 10) \\ &= 1 - \mathbb{P}(|S_n - \mathbb{E}[S_n]| > 10) \\ &\geq 1 - \frac{\text{Var}(S_n)}{10^2} \\ &= 1 - \frac{100}{12 \cdot 10^2} \\ &= \frac{11}{12}.\end{aligned}$$

Что это значит?

Центральная предельная теорема. Концентрация II

По центральной предельной теореме:

$$\begin{aligned}\mathbb{P}(|S_n - 7500| \leq 10) &= \mathbb{P}(-10 \leq S_n - \mathbb{E}[S_n] \leq 10) \\&= \mathbb{P}\left(-\frac{10}{\sqrt{100/12}} \leq \frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}} \leq \frac{10}{\sqrt{100/12}}\right) \\&= \mathbb{P}\left(-2\sqrt{3} \leq \frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}} \leq 2\sqrt{3}\right) \\&\approx \Phi(2\sqrt{3}) - \Phi(-2\sqrt{3}) \\&\approx 0.9994.\end{aligned}$$

Что это значит?

Лемма Джонсона-Линденштраусса

Поговорим о задаче снижения размерности.

Будем рассматривать наблюдения u_1, u_2, \dots, u_n как точки \mathbb{R}^D .

	Признак 1	Признак 2	...	Признак D
u_1				
u_2				
...				
u_n				



Хранить все D координат каждой точки u_i может быть «дорого».

Лемма Джонсона-Линденштраусса

Мы хотим придумать такое отображение $F : \mathbb{R}^D \rightarrow \mathbb{R}^d$ для данных u_1, u_2, \dots, u_n , которое бы сохраняло их «структуру» и d было бы намного меньше D .

Что можно понимать под «структурой» данных?

Один из вариантов ответа на этот вопрос — попарные расстояния между точками u_1, u_2, \dots, u_n .



Лемма Джонсона-Линденштраусса

Формально можно записать так:

1) $\|F(u_i) - F(u_j)\| = \|u_i - u_j\|$ для всех $i \neq j$.

В этом случае можно понизить размерность до

$$d = n - 1.$$

2) $(1 - \delta)\|u_i - u_j\|^2 \leq \|F(u_i) - F(u_j)\|^2 \leq (1 + \delta)\|u_i - u_j\|^2$
для некоторого $\delta \in (0, 1)$ всех $i \neq j$.

В этом случае можно понизить размерность до

$$d = n - 1.$$

Лемма Джонсона-Линденштраусса

Что делать дальше?

- 3) Потребуем, чтобы с вероятностью не менее $1 - \varepsilon$, для некоторого $\varepsilon > 0$:

$$(1 - \delta)\|u_i - u_j\|^2 \leq \|F(u_i) - F(u_j)\|^2 \leq (1 + \delta)\|u_i - u_j\|^2$$

для некоторого $\delta \in (0, 1)$ всех $i \neq j$.

В этом случае можно понизить размерность до

$$d \geq \frac{16}{\delta^2} \log \left(\frac{n}{\varepsilon} \right).$$

Лемма Джонсона-Линденштраусса

$$d \geq \frac{16}{\delta^2} \log \left(\frac{n}{\varepsilon} \right)$$

- ▶ Логарифмическая зависимость от n !
- ▶ Отображение $F(u)$ можно построить явно!

$$F(u) = \frac{1}{\sqrt{d}} X u,$$

где X — матрица размера $d \times D$, у которой все элементы — независимые $\mathcal{N}(0, 1)$ величины.

- ▶ Можно использовать алгоритм онлайн (не зная наперед данные).

Свойства оценок

Пусть дана реализация выборки x_1, \dots, x_n из некоторого распределения с неизвестным параметром θ . Для простоты будем считать, что θ одномерный.

Допустим, мы построили оценку $\hat{\theta}$ для параметра θ . Как понять, является она хорошей или нет.

Свойства оценок

Оценка $\hat{\theta}(x_1, \dots, x_n)$ параметра θ называется **несмещенной**, если

$$\mathbb{E}_{\theta} \left[\hat{\theta}(X_1, \dots, X_n) \right] = \theta \quad \text{для всех } \theta \in \Theta.$$

Здесь индекс θ у математического ожидания \mathbb{E}_{θ} означает, что мы считаем математическое ожидание случайной величины $\hat{\theta}(X_1, \dots, X_n)$, где X_i распределены с параметром θ .

Несмещенность означает, что при многократном вычислении оценки на разных данных среднее арифметическое полученных оценок будет стремиться к истинному значению параметра θ .

Свойства оценок

Оценка $\hat{\theta}(x_1, \dots, x_n)$ параметра θ называется **состоятельной**, если для всех $\theta \in \Theta$

$$\hat{\theta}(X_1, \dots, X_n) \xrightarrow{\mathbb{P}_\theta} \theta \quad \text{при } n \rightarrow \infty.$$

Состоятельность оценки означает концентрацию оценки около истинного значения параметра с ростом размера выборки n (что устремив $n \rightarrow \infty$, оценка сойдется к истинному значению параметра θ).

Свойства оценок

Какими свойствами обладают оценки, полученные методом максимального правдоподобия?

При некоторых условиях на регулярность модели:

- ▶ Возможная смещённость
- ▶ Состоятельность
- ▶ Асимптотическая эффективность

Это означает, что дисперсия при $n \rightarrow \infty$ является наименьшей возможной среди многих других оценок.

Оценивание характеристик распределения

Теперь допустим нам дана реализация выборки x_1, \dots, x_n из некоторого распределения, о котором мы ничего не знаем. Что можно сделать в данном случае?

Естественно, точно восстановить распределение по конечной выборке нельзя. Но можно оценить какие-то параметры распределения!

Оценивание характеристик распределения

Допустим, мы хотим оценить $\mathbb{E}[g(X)]$, где X — случайная величина, из распределения которой получена выборка, а $g : \mathbb{R} \rightarrow \mathbb{R}$ — некоторая (известная) функция.

Это можно сделать с помощью **оценки Монте-Карло**:

$$\frac{1}{n} \sum_{i=1}^n g(x_i).$$

Оценивание характеристик распределения

Оценка Монте-Карло является несмещенной и состоятельной.

1. Несмещенность:

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n g(X_i) \right] = \frac{1}{n} \left(\mathbb{E}[g(X_1)] + \dots \mathbb{E}[g(X_n)] \right) = \mathbb{E}[g(X)].$$

2. Состоятельность: согласно закону больших чисел

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow{\mathbb{P}} \mathbb{E}[g(X)].$$

Оценивание характеристик распределения

Примеры:

1. Математическое ожидание:

$$\mathbb{E}[X] \approx \frac{1}{n} \sum_{i=1}^n x_i.$$

2. Моменты большего порядка: для $k > 1$

$$\mathbb{E}[X^k] \approx \frac{1}{n} \sum_{i=1}^n x_i^k.$$

3. Более сложные функции. Например:

$$\mathbb{E}[X^3 \sin(X) \log(X)] \approx \frac{1}{n} \sum_{i=1}^n x_i^3 \sin(x_i) \log(x_i).$$

Оценивание характеристик распределения

Чтобы оценить погрешность метода Монте-Карло, можно воспользоваться центральной предельной теоремой.

Аналогично тому, как было в законе больших чисел

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n g(X_i)\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[g(X_i)] = \mathbb{E}[g(X)],$$
$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n g(X_i)\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}[g(X_i)] = \frac{\sigma^2}{n},$$

где $\sigma^2 = \text{Var}[g(X)]$ по определению.

Оценивание характеристик распределения

По центральной предельной теореме: для произвольных $a < b$

$$\mathbb{P} \left(a \leq \frac{\frac{1}{n} \sum_{i=1}^n g(X_i) - \mathbb{E}[g(X)]}{\sigma/\sqrt{n}} \leq b \right) \approx \mathbb{P}(a \leq Z \leq b),$$

где $Z \sim \mathcal{N}(0, 1)$.

Если взять $a = -3$ и $b = 3$ («правило трех сигм»), то мы получим $\mathbb{P}(-3 \leq Z \leq 3) \approx 0.997$.

В результате:

$$\left| \frac{1}{n} \sum_{i=1}^n g(X_i) - \mathbb{E}[g(X)] \right| \leq 3\sigma \cdot \frac{1}{\sqrt{n}} \quad \text{с вероятностью } \approx 0.997.$$

Оценивание характеристик распределения

А как на основе реализации выборки x_1, \dots, x_n из некоторого распределения X оценить дисперсию $\text{Var}(X)$? Или какой-то другой центральный момент?

Оценивание характеристик распределения

Если бы математическое ожидание $\mathbb{E}[X]$ было бы известным, можно было бы воспользоваться оценкой Монте-Карло:

$$\frac{1}{n} \sum_{i=1}^n (x_i - \mathbb{E}[X])^2.$$

Но что делать, если $\mathbb{E}[X]$ неизвестно?

Оценивание характеристик распределения

Plug-in principle: если оценка неизвестного параметра требует знания каких-то других неизвестных параметров, то можно попробовать подставить в эту оценку вместо неизвестных параметров их оценки.

При этом, естественно, нет никаких гарантий, что полученная оценка будет хорошей.

Оценивание характеристик распределения

Обозначим оценку для математического ожидания через \bar{x} ,

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Подставим ее в оценку для дисперсии, которая была выше:

$$\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Данная оценка будет состоятельной, но смещенной.

Оценивание характеристик распределения

Действительно, используя свойства математического ожидания, получаем:

$$\begin{aligned}\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n X_i^2 - \frac{1}{n^2} \sum_{i,j=1}^n X_i X_j \right] \\&= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i^2] - \frac{1}{n^2} \sum_{i=1}^n \mathbb{E}[X_i^2] - \frac{1}{n^2} \sum_{i \neq j} \mathbb{E}[X_i] \mathbb{E}[X_j] \\&= \mathbb{E}[X^2] - \frac{1}{n} \mathbb{E}[X^2] - \frac{n-1}{n} (\mathbb{E}X)^2 \\&= \frac{n-1}{n} \text{Var } X.\end{aligned}$$

Оценивание характеристик распределения

Чтобы устранить смещение, достаточно домножить оценку на $n/(n-1)$. Мы получили несмещенную оценку для дисперсии:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Смещенную оценку дисперсии будем обозначать через:

$$S_b^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Оценивание характеристик распределения

Оценка стандартного отклонения по смещённой оценке дисперсии:

$$\hat{\sigma}_b = \sqrt{S_b^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Оценка стандартного отклонения по несмещённой оценке дисперсии:

$$\hat{\sigma} = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Оценивание характеристик распределения

Обе оценки являются смещёнными, так как извлечение квадратного корня «портит» несмещённость. Но при этом обе оценки являются состоятельными.

Доверительные интервалы

Пусть имеется реализация выборки x_1, \dots, x_n из некоторого распределения с неизвестным (одномерным) параметром

$$\theta \in \Theta \subset \mathbb{R}.$$

До сих пор мы занимались «точечным оцениванием» неизвестного параметра — находили оценку, способную в некотором смысле заменить параметр.

Существует другой подход к оцениванию, при котором мы указываем интервал, накрывающий параметр с заданной наперед вероятностью. Такой подход называется «интервальным оцениванием».

Доверительные интервалы

Пусть $\alpha \in (0, 1)$. Две оценки $\hat{\theta}_1$ и $\hat{\theta}_2$ определяют границы доверительного интервала для параметра θ с коэффициентом доверия $1 - \alpha$, если для выборки $\mathbf{X} = (X_1, \dots, X_n)$ из закона распределения F_θ при всех $\theta \in \Theta$ справедливо неравенство

$$\mathbb{P}(\hat{\theta}_1(\mathbf{X}) < \theta < \hat{\theta}_2(\mathbf{X})) \geq 1 - \alpha.$$

Как правило, длина доверительного интервала возрастает при увеличении коэффициента доверия $1 - \alpha$ и стремится к нулю с ростом размера выборки n .

Спасибо за внимание!